

Digitale Ethik: KI und Arbeit, Gefahr diskriminierender Verhaltensmuster (Teil 2)

Eine kurze Einführung und Fallstudien

Prof. Dr. Ladan Pooyan-Weihs

Rotkreuz, FS 2026

Agenda

- **Zielsetzung & Herausforderungen**

Teil 1

- **Grundlagen**

- Wie kamen wir zur künstlichen Intelligenz (KI)?
- Landkarte der Grundbegriffe
- Turing Test
- Einführung in Maschinelles Lernen
- Was bedeutet das Lernen oder Voraussagen bei Maschinen/Computern?

Teil 2

- **Ethische Reflexionen**

- Warum digitale Ethik?
- Vertrauen ML-Empfehlungen?

- **Handlungsempfehlungen**

- Wertesysteme
- Participatory Design: ein möglicher Ansatz bei der Entwicklung der ML-Anwendungen

- **Literatur**

ETHISCHE REFLEXIONEN

Meinungsumfrage

WARUM „DIGITALE ETHIK“?


Warum Digitale Ethik?

- Der Einsatz von KI- und Big-Data-Anwendungen in vielen Lebensbereichen ist alltäglich geworden.
- Auf IT basierende Entscheidungen beeinflussen Wirtschaft und Gesellschaft zunehmend direkt und tiefgreifend.
- Die Technologie um uns herum entwickelt sich rasch und weitgehend ohne grundlegende ethische Überlegungen sowie ohne ganzheitliche politische Regulierungen.
- Die Informationstechnologie ist nicht nur an sich mächtig; sie erleichtert auch den Erfolg und die Konvergenz anderer bedeutender Technologien wie KI, Neurologie, Pharmakologie, Big Data - Analytics und Robotik.
- Die Rolle der Informatikerinnen und Informatiker hat sich im Zeitalter der Digitalisierung neu definiert.

Warum Digitale Ethik?

- Die Forderungen nach nachhaltigem und ethischem Handeln bei der Softwareentwicklung und KI-Anwendungen werden zunehmend lauter.
- In der Schweiz wird dieses Thema verstärkt diskutiert (Swiss Digital Initiative, NZZ, 27.09.2019).
- Einige europäische Hochschulen, wie die Wirtschaftsuniversität Wien oder die TU Braunschweig, bieten bereits vollständige Bildungsprogramme (z. B. Masterprogramme) oder einzelne Seminare zu diesem Thema an.

Vertrauen ML-Empfehlungen?



Vertrauen ML-Empfehlungen?



Sende eine Nachricht an ChatGPT




ChatGPT kann Fehler machen. Überprüfe wichtige Informationen.

Qualität der Daten und Datenethik

- Die Trainings- und Testdaten müssen **vollständig** sein, damit **alle diejenigen** Gruppen, die von den ML-Empfehlungen betroffen sind, vom Algorithmus in der Tat auch berücksichtigt und entsprechend behandelt werden.
- Als am meistens genannte **Qualitäts**merkmal für den Einsatz der ML-Programme gilt das Argument, dass Algorithmen **nicht auf Voreingenommenheit** reagieren. Viele Studien haben gezeigt, dass das "Data Mining" die Vorurteile früherer Entscheidungsträger erben oder die weit verbreitete Voreingenommenheit widerspiegeln kann, die in der Gesellschaft insgesamt bestehen.
- Die Empfehlungsprogramme führen **keine neuen** Voreingenommenheit/Bias ein, wie es ein menschlicher Entscheidungsträger tun könnte. Sie können jedoch ohne eine sehr **sorgfältige** Datensammlung und -bereinigung **im Vorfeld**, die in ihren Datensätzen implizierten Bias doch **reproduzieren und verewigen**.
- ML-Systeme benötigen eine grosse Menge der Daten zum Training. Für das überwachte Lernen müssen diese Daten auch markiert werden. Dies Markierung wird von den Menschen gemacht. Dies Menschen werden durch **Crowd-Sourcing** Business Modell rekrutiert und arbeiten unter prekären Arbeitsverhältnissen (Lucas Biewald CEO von Figur8Crowdfunder <https://www.youtube.com/watch?v=AfRMH0glHeg> und 23 cent für 30 Min. Arbeit). Die International Labor Organisation (ILO) in Genf kritisierte sehr vehement diese Praktiken. (Mehr dazu <https://youtu.be/pFoU-cBCPMk>).

Vertrauen ML-Empfehlungen?



Ethische Vertretbarkeit der Empfehlungen der KI-Modelle



Quelle: Shouldigetaphd.com

Ethische Probleme bei der Anwendung der KI-Modelle am Beispiel ChatGPT

Wo können bei der Verwendung von KI-Modellen wie ChatGPT ethische Probleme auftreten?



Quelle: Wonderopolis.com

Ethische Probleme bei der Anwendung der KI-Modelle

Wo können bei der Verwendung von KI-Modellen wie ChatGPT ethische Probleme auftreten?

Im Zusammenhang mit


- Datenschutz
- Traumatisierende Datenkennzeichnung
- Vorurteilen
- Missbrauch, Desinformation
- Transparenz und Verantwortlichkeit
- Ressourcen und Umwelt
- Abhängigkeit von KI



Quelle: Wonderopolis.com

Ethische Probleme: Datenschutz

«Die Verwendung von ChatGPT erfordert die Bereitstellung von Textdaten, die möglicherweise **sensible Informationen** enthalten. Der Schutz dieser Daten und die Sicherstellung der **Privatsphäre** der Benutzer sind wichtige ethische Überlegungen.»



Quelle: blog.devolutions.net

Ethische Probleme: Datenschutz



Italien blockiert den ChatGPT-Chatbot

31.03.2023

„Die italienischen Behörden gaben am Freitag ihre Entscheidung bekannt, den Chatrobot ChatGPT zu sperren, da er angeblich gegen die Datenschutzgesetze verstösst und kein System zur Überprüfung des Alters von minderjährigen Nutzern hat“.

Die Behörde wirft OpenAI auch "das Fehlen eines Informationsschreibens an die Nutzer, deren Daten gesammelt werden, vor, aber vor allem das Fehlen einer Rechtsgrundlage, die das massenhafte Sammeln und Speichern von persönlichen Daten rechtfertigt, um die Algorithmen, die die Plattform betreiben, zu trainieren".



Quelle: Romain Doucelin & Hans Lucas / AFP

Ethische Probleme: Traumatisierende Datenetikettierung

≡ netzwoche

ChatGPT in Kenia: Menschen als Filter für problematische Inhalte

20.01.2023


Jetzt ist klar, wie OpenAI seine KI-Modelle wie ChatGPT daran hindert, hochproblematische Inhalte von sich zu geben: Das Unternehmen setzte auf Angestellte in Kenia, die verstörende und illegale Inhalte sichten und kennzeichnen – für weniger als 2 US-Dollar pro Stunde.



Quelle: Michael Dzedzic /Unsplash.com

Ethische Probleme: Vorurteile


«KI-Modelle können Vorurteile aus den Trainingsdaten übernehmen, was zu diskriminierenden oder unfairen Antworten führen kann. Die Ethik erfordert, dass solche Vorurteile **erkannt** und **minimiert** werden.»



Quelle: Lexisnexis.com

Ethische Probleme: schädliche Aktivitäten, Missbrauch, Desinformation

«Die Möglichkeit, ChatGPT für betrügerische oder schädliche Aktivitäten zu missbrauchen, ist ein ernstes ethisches Problem. Dies kann Spamming, **Desinformation** oder sogar **Manipulation** von Meinungen umfassen.»



Quelle: exhibit.tech

Ethische Probleme: schädliche Aktivitäten, Missbrauch, Desinformation

BBC

OpenAI faces criminal probe over role of ChatGPT in shooting

21 April 2026

Share

Save

Add as preferred on Google

Lesezeichen in diesem Ordner anzeigen

Technology reporter



Family of Florida university shooting victim sues over suspect's ChatGPT use

Federal lawsuit against OpenAI says alleged gunman had extensive conversations with chatbot over months



Quelle: The Guardian

Ethische Probleme: Ressourcen und Umwelt


Frankfurter Allgemeine

28.09.2023

So viel Wasser verbrauchen Chatbots

Künstliche Intelligenz kann beim Energiesparen helfen, verbraucht aber selbst auch viel Energie. Und Wasser, wie eine neue Studie aus den USA zeigt.

Der eigentliche Verbrauch beginne aber erst nach dem Training: Die Forscher schreiben, dass Chat-GPT für alle 20 bis 50 beantworteten Fragen, einen halben Liter Wasser brauche – abhängig von Ort und Zeitpunkt mal mehr und mal weniger. Das wirke zwar erst einmal wenig, aufgrund der hohen Nutzerzahlen sei es aber trotzdem viel Wasser. Zudem gehen die Studienautoren davon aus, dass der Verbrauch von GPT-4 höher ist.



Quelle: Reuters


Ethische Probleme: Abhängigkeit von KI

«Die übermässige Abhängigkeit von KI-Modellen wie ChatGPT für wichtige Entscheidungen kann ethische Fragen aufwerfen, **insbesondere** wenn menschliche Überlegungen und Verantwortlichkeiten **umgangen** werden.»



Quelle: nytimes.com

Vertrauen ML-Empfehlungen?



Worauf kommt es an?

DESIGNQUALITÄT DER KI- ALGORITHMEN

Design von KI-Anwendungen: Worauf kommt es an?

- **Ziel: nützlichere und sicherere Kollaboration**
- Wie kann man eine KI-Anwendung so gestalten, damit sie nützlicher, sicherer und angenehmer zu benutzen ist?
 - Interne Struktur
 - Wahl der Algorithmen
 - Wahl der Programmiersprachen
 - Interaktion zwischen Mensch-Maschine, User Interface ...
 - Explicable AI (Erklärbarkeit von KI-Anwendungen wie z. B. Roboters, Chatbots ...): Man **verst**eht, wie der Roboter arbeitet, um in der Lage zu sein, den nächsten Schritt vorauszusagen

Wann erfüllt eine SW nicht die erwarteten Ziele?

- 1. Kategorie: Die SW werden von Fachexperten mit keiner oder geringer Erfahrung im Bereich der Mensch-Maschine-Interaktion entworfen
 - Beispiel: Eine PANOPLY* Infusionspumpe für Chemotherapie wurde von einem Unternehmen mit exzellenten fachlichen Kenntnissen in Krebsbehandlung aber mit keiner Erfahrung im Bereich Mensch-Maschine-Interaktion entwickelt. Was waren die Konsequenzen?
- 2. Kategorie: Die SW wurden so entworfen, damit bestimmte Ziele erfüllt sind. Diese Ziele sind jedoch heimtückisch
 - Beispiel: Notifikationen von Applikationen. Was ist das Ziel von Notifikationen? Meta (Facebook (FB)) oder Youtube erlaubt nicht wirklich die Parametrisierung der Notifikationen, weil die Users häufiger auf FB bleiben sollen ...

*: PANOPLY ist eine Cloud-basierte Plattform für die automatisierte und reproduzierbare Analyse proteogenomischer Daten, die modernste statistische und maschinelle Lernalgorithmen verwendet, um multiautomatische Daten aus Krebsproben in biologisch aussagekräftige und interpretierbare Ergebnisse umzuwandeln.

Wann erfüllt eine SW nicht die erwarteten Ziele?

- 3. Kategorie: Die SW wurden mit schädlichen Auswirkungen entworfen: Bestrafung oder Ausgrenzung bestimmter Personen, Bevorzugung bestimmter Gruppen gegenüber anderen, Förderung von unsozialem und antidemokratischem Verhalten
- Beispiele auf [Amnesty Tech](#)

Beispiel: Subjektive Bias auf schädliche Weise

- **Gesundheitsversorgung:** Um die Gesundheitsversorgung möglichst effektiv zu gestalten, kommt in den USA ein ML-Programm zum Einsatz, welches Patient:innen mit besonderem Pflegebedarf identifiziert. Eine im Oktober 2019 veröffentlichte Studie zeigt allerdings auf, dass Afroamerikaner:innen bei gleicher Krankheitsschwere, seltener für extra Pflege vorgeschlagen wurden als Weiße. Tatsächlich hätte ein ML-Programm ohne Bias, die doppelte Anzahl von Afroamerikaner:innen mit besonderem Pflegebedarf ausweisen müssen. Wie kam eine eigentlich „farbenblinde“ KI zu solchen Ergebnissen?
- Der Algorithmus dieser KI definierte das Risiko der Patient:innen, als die zu erwartenden Kosten der weiteren Behandlung. Da aufgrund diverser Faktoren der US-amerikanische Staat weniger Geld für die Behandlung von Afroamerikaner:innen ausgibt, wurden die Kosten und somit auch das Risiko für Angehörige dieser Ethnizität als geringer eingeschätzt (Obermeyer et al., 2019).

Selbststudium

Ein Link zum Artikel mit dem Titel

[Ethical Considerations for Using AI to Predict Suicide Risk](#)

Während KI das Potenzial hat, die Vorhersage des Suizidrisikos zu verbessern, muss ihre Integration in die klinische Praxis mit Vorsicht erfolgen. Ethische Überlegungen zu Offenlegung, Einwilligung und der Nutzung von Daten sind von größter Bedeutung. Wenn Patientendaten, die während der klinischen Versorgung gesammelt werden, verwendet werden, um diese Algorithmen weiter zu trainieren, verwischt dies die Grenze zwischen klinischer Praxis und Forschung. Wichtig ist, dass der Nutzen der KI-Vorhersagen davon abhängt, wie gut sie effektive, mitfühlende und menschenzentrierte Interventionen unterstützen. Ohne angemessene Nachsorge und Unterstützung bieten die prädiktiven Fähigkeiten der KI nur begrenzte Vorteile.

Selbststudium & Diskussion

Ein Link zum Artikel mit dem Titel

[The Death Algorithm — Will Google Influence Your Lifespan?](#)

Inwiefern bringt dieser «Algorithmus zur Mortalität» mögliche Vorteile, aber auch gesellschaftliche, ethische Nachteile mit sich?

Wer übernimmt die Verantwortung für fehlerhafte Empfehlungen?

- Wer trägt die Verantwortung für Verzerrungen in KI-Systemen – die Datenlieferanten, die Entwickler, die Nutzer oder der Gesetzgeber?
- Sollten Organisationen für die Bereitstellung verzerrter historischer Daten haftbar gemacht werden, wenn diese zu diskriminierenden KI-Entscheidungen führen?
- Welche Schritte können wir unternehmen, damit die KI-Algorithmen umfassend begutachtete Daten (vollständig gesammelt und möglichst frei von Bias) verarbeiten? An welchem Schritt im Prozess sollte diese Begutachtung stattfinden?

HANDLUNGSEMPFEHLUNGEN

Ethische Probleme bei der Anwendung der KI-Modelle



Quelle: Shouldigetaphd.com


Wertesysteme

ETHISCHE VERTRETBARKEIT DER KI- ANWENDUNGEN SICHER STELLEN

Ethische Vertretbarkeit der KI-Anwendungen

Entwurf durch Wertesysteme

- Frage: Kann ein Wertesystem wie z. B. die vier Werte der UNESCO* eine ausreichende Rahmenbedingung für den Entwurf der KI-Anwendungen anbieten?



- Antwort: Das folgende Beispiel hilft eine Antwort zu formulieren.

*:<https://www.unesco.org/en/artificial-intelligence/recommendation-ethics?hub=32618>

Ethische Vertretbarkeit der KI-Anwendungen

10 aus dem UNESCO-Wertesystem* resultierende Prinzipien für einen menschenrechtlichen Ansatz für KI

1. Verhältnismässigkeit und Do No Harm
2. Sicherheit und Schutz
3. Recht auf Privatsphäre und Datenschutz
4. Multi-Stakeholder und adaptive Governance & Zusammenarbeit (Diversität und Inklusion in den Entwicklerteams, ...)
5. Verantwortung, Haftung und Rechenschaftspflicht
6. Transparenz und Erklärbarkeit
7. Menschliche Aufsicht und Entschlossenheit
8. Nachhaltigkeit
9. Sensibilisierung, Schulung (Data Literacy: Data Science, KI, ...)
10. Fairness und Nicht-Diskriminierung

*:<https://www.unesco.org/en/artificial-intelligence/recommendation-ethics?hub=32618>

Beispiel: Entscheidungsfindung in der Medizin

Szenario: Sie arbeiten in einem Team, das eine KI-Anwendung für die autonome Entscheidungsfindung in der Medizin entwickelt. Diese Anwendung soll Ärzte bei der Diagnose von Krankheiten unterstützen und Therapieempfehlungen geben. Die KI analysiert medizinische Daten, Krankengeschichten und Forschungsergebnisse, um personalisierte Empfehlungen zu erstellen.

Entwurf der Lösung: In welchen Themen sollte das Team einige Fragen vor der Implementierung beantwortet haben, damit die Lösung bestmöglich ethisch vertretbar ist?

Antwort: Zusammenarbeit im Unterricht.

Beispiel: Entscheidungsfindung in der Medizin

Mögliche ethische Themen im Rahmen der 10 Prinzipien:

1. Patientenautonomie und Entscheidungsgewalt
2. Datenschutz und Patienteninformation
3. Verantwortlichkeit und Haftung
4. Bias und Gerechtigkeit

Beispiel: Entscheidungsfindung in der Medizin

Formulieren Sie einige Fragen in Bezug auf „Patientenautonomie und Entscheidungsgewalt“ (1, 2, 6, 10)

- Wie können ethische Prinzipien wie die Autonomie der Patienten respektiert werden, wenn die KI autonome Entscheidungen trifft? Implementierung von "Explainable AI" (nachvollziehbare KI), um den Entscheidungsprozess transparent zu machen und Patienten zu ermöglichen, die Empfehlungen zu verstehen.
- Welche Mechanismen könnten implementiert werden, um die Entscheidungsgewalt bei den Patienten zu belassen? Einführung von Optionen für Patienten, die Autonomie über ihre medizinischen Entscheidungen zu behalten oder zu übertragen.

Beispiel: Entscheidungsfindung in der Medizin

Formulieren Sie einige Fragen in Bezug auf „Datenschutz und Patienteninformation“. (3)

- Welche ethischen Überlegungen sind bei der Verwendung sensibler medizinischer Daten wichtig?
- Wie kann der Datenschutz gewährleistet werden, und wie sollten Patienten über die Verwendung ihrer Daten informiert werden?

Beispiel: Entscheidungsfindung in der Medizin

Formulieren Sie einige Fragen in Bezug auf „Verantwortlichkeit und Haftung“. (5)

- Wer trägt die ethische und rechtliche Verantwortung, wenn die KI falsche Diagnosen stellt oder ungeeignete Therapieempfehlungen gibt?
- Wie kann die Haftung klar geregelt und dennoch Innovation in der medizinischen KI-Entwicklung ermöglicht werden?

Beispiel: Entscheidungsfindung in der Medizin

Formulieren Sie einige Fragen in Bezug auf „Bias und Gerechtigkeit“. (1, 7, 9, 10)

- Wie kann sichergestellt werden, dass die KI-Anwendung nicht durch Bias beeinflusst wird und gerechte Empfehlungen für verschiedene Bevölkerungsgruppen gibt?
- Welche ethischen Richtlinien sollten für die Entwicklung von KI-Algorithmen gelten, um Vorurteile zu minimieren?

Best Practices beim Design von KI-Systemen am Beispiel

PARICIPATIRY DESIGN

Chinesische Weisheit

Wenn der falsche Mann die richtigen Mittel anwendet,
wirken die richtigen Mittel auf die falsche Weise!

Was ist Participatory Design (PD)?

Entstehungskontext

- Soziale Bewegungen und Bürgerrechtsbewegungen in den 1960er und 1970er Jahren
- Menschen fordern Teilhabe an Entscheidungen über Aspekte ihres Lebens
- **Kollektives Handeln** für **gemeinsame Interessen und Werte** als Ausgangspunkt für Participatory Design von IT:
 - Bewegung für Demokratie am Arbeitsplatz in den 1970er Jahren, insbesondere in Skandinavien
 - Reaktion auf Transformation von Arbeitsplätzen durch Einführung von Computern
 - Überzeugung, dass diejenigen, die IT nutzen, eine starke Rolle im Design von IT spielen sollten d.h. PD zielt darauf, zukünftige Situationen zu gestalten

Participatory Design (PD)

- Dieser Ansatz ist eine Sammlung von Entwurfspraktiken zur Einbeziehung der zukünftigen Nutzer:innen des Designs als Co-Designer in den Designprozess.
- PD wird in einer Vielzahl von Bereichen von Software- und Produktdesign, Städtebau, Architektur, Grafikdesign, Arbeitsorganisation bis hin zur Medizin eingesetzt.
- Die Methodik von PD ist basiert auf der echten Entscheidungsbefugnis der Mitgestalter:innen und der Einbeziehung ihrer Werte in den Designprozess.
- Mitgestalter werden generationsübergreifend, multidisziplinär und unter Betrachtung der hohen Diversität (gender, geographisch, soziale Hintergrund ...) zusammengestellt.
- Das Ergebnis der Teamarbeit ist oft ein hochpräziser Prototyp für ein Produkt oder eine Dienstleistung oder eine neue Art der Organisation/einer Arbeitspraxis oder der Gestaltung eines Raumes oder einer Software.

Schlussfolgerung

Schlussfolgerung

- KI-Systeme können grosse Datenmengen verarbeiten, Muster darin erkennen, Rückschlüsse daraus ziehen und effektive Handlung empfehlen. Sie arbeiten schneller und genauer als Menschen.
- KI-Systeme können eingesetzt werden, um menschliche Entscheidungsprozesse zu **unterstützen** oder autonome **nachvollziehbare** Entscheidungen zu treffen.
- Das Verhalten von KI-Systemen müssen **validiert**, **vorhersagbar** und **erklärbar** sein.
- Die Ergebnisse eines gegebenen Algorithmus muss studiert werden, um festzustellen, ob irgendwelche Gruppen der Menschen benachteiligt oder ausgeschlossen werden. Dann sollte überlegt werden, wie diese Gruppen in das KI-System integriert werden könnten.
- Es ist notwendig, **verantwortungsvoller** über die Gestaltung von KI-Systemen nachzudenken und keine ungerechten Vorurteile aufrechtzuerhalten.

Reflexionsfragen

- Sollten wir uns mit der Zuverlässigkeit, Robustheit und Sicherheit von KI-Systemen intensiver auseinandersetzen?
- Müssen KI-Systeme auch während des laufenden Betriebs kontinuierlich überwacht werden?
- Wie können wir sicherstellen, dass sich das Verhalten von KI-Systemen an sozialen Normen und menschlichen Werten orientiert?
- Wie erkennen wir, wann ein KI-System eine „falsche“ Entscheidung trifft – und wer trägt in einem solchen Fall die Verantwortung?
- Wie sollten wir KI-Systeme testen, um ihre Zuverlässigkeit und Fairness zu gewährleisten?
- Für welche Anwendungsbereiche sind KI-Systeme tatsächlich geeignet – und wo sollten wir auf ihren Einsatz verzichten?
- Wer profitiert vom Einsatz von KI-Systemen – z. B. in Bezug auf Lebensqualität, Arbeitsverteilung oder wirtschaftliche Vorteile?
- Kann das Prinzip des „Participatory Design“ helfen, bestimmte Probleme bereits in der Entwicklungsphase von KI-Anwendungen zu vermeiden?

Literatur

Arendt, H. (1958). *Vita Activa*, Piper-Taschenbuch.

Julia, L. (2020). There is no such thing as artificial intelligence.

Pooyan-Weihs, L. (2020). Künstliche Intelligenz gibt es eigentlich nicht, <https://hub.hslu.ch/informatik/kunstliche-intelligenz-gibt-es-nicht-wichtig-ist-digitale-ethik/> , abgerufen 23.11.2023

Russell, S. J., Norvig, P. (2010). *Artificial Intelligence - A Modern Approach (4. internat. ed.)*. Pearson Education.

Spiekermann, S. (2016). *Ethical IT innovation: A value-based system design approach*. CRC Press.

Spiekermann, S. (2019). *Digitale Ethik. Ein Wertesystem für das 21. Jahrhundert*. Droemer.

Staab, S., Stalla-Bourdillon, S., and Carmichael, L. (2016). Observing and recommending from a social web with biases. CoRR, abs/1604.07180.

YanMa, Ku, Kang Liu et al. Background Augmentation Generative Adversarial Networks (BAGANs): Effective Data Generation Based on GAN-Augmented 3D Synthesizing, Symmetry 2018, 10, 734 (www.mdpi.com)