APRIL 12, 2026

ANONYMISIERUNG: SYNTHETISCHE DATENGENERIERUNG UND MASCHINELLES LERNEN

PRIVACY & TECHNOLOGY MODUL LAB A/B

BENJAMIN WÜRMLI, DIEGO KURZ, DOMINIK DIERBERGER, SOFIA GEORGIADOURGER
HSLU

1 CONTENTS

2 Einleitung....2
3 Konzept synthetischer Daten....3
4 Aufbau des Projekts....4
5 Ergebnisse....6
6 Chancen und Risiken....7
7 Fazit....8

2 EINLEITUNG

Im Bereich Datenschutz und Privatsphäre stellt sich oft die Frage, wie sensible Daten für Forschung oder maschinelles Lernen genutzt werden können, ohne dabei die betroffenen Personen zu gefährden. Besonders schwierig ist das im Gesundheitsbereich, weil medizinische Daten sehr persönlich sind und deshalb besonders gut geschützt werden müssen.

Eine mögliche Lösung dafür sind **synthetische Daten**. Das sind künstlich erzeugte Datensätze, die sich an echten Daten orientieren, aber keine realen Personen direkt enthalten sollen. Die Idee dahinter ist, dass man mit solchen Daten trotzdem Modelle trainieren, Tests durchführen oder Analysen machen kann, ohne Originaldaten weiterzugeben.

In diesem Projekt geht es darum, einen kleinen medizinischen Datensatz zu simulieren, daraus synthetische Daten zu erzeugen und anschliessend zu prüfen, wie gut sich diese Daten für ein einfaches Machine-Learning-Modell eignen. Gleichzeitig ist auch wichtig zu untersuchen, ob durch die synthetischen Daten ein Datenschutzrisiko entsteht.

Als Beispiel wurde ein Datensatz mit Patientendaten im Zusammenhang mit **Diabetes** verwendet.

3 KONZEPT SYNTHETISCHER DATEN

Synthetische Daten sind künstlich erzeugte Daten, die die wichtigsten statistischen Eigenschaften eines echten Datensatzes nachbilden sollen. Dazu gehören zum Beispiel Verteilungen einzelner Merkmale, aber auch Zusammenhänge zwischen verschiedenen Variablen.

Der Vorteil solcher Daten ist, dass sie einfacher geteilt und für Experimente genutzt werden können als echte personenbezogene Daten. Trotzdem sind sie nicht automatisch anonym oder risikofrei. Wenn ein Modell zu nahe an den Originaldaten lernt, kann es passieren, dass einzelne reale Personen indirekt wiedererkennbar werden.

Grundsätzlich gibt es verschiedene Möglichkeiten, synthetische Daten zu erzeugen:

Methode	**Beschreibung**	**Einschätzung**
Regelbasiert	Werte werden zufällig nach festen Regeln erzeugt	einfach, aber wenig realistisch
Statistische Modelle	Verteilungen und Korrelationen werden modelliert	gut für strukturierte Daten
Deep-Learning-Modelle	komplexe Muster werden mit neuronalen Netzen gelernt	leistungsfähig, aber aufwendiger

In diesem Projekt wurden zwei Methoden aus der **SDV-Bibliothek** verwendet:

- **GaussianCopula**
- **CTGAN**

GaussianCopula

GaussianCopula ist ein statistisches Verfahren. Es versucht, die Verteilungen einzelner Spalten und die Zusammenhänge zwischen ihnen zu modellieren. Danach werden aus diesem Modell neue Daten erzeugt.

Der Ansatz ist relativ schnell und funktioniert oft gut bei tabellarischen Daten. Er ist aber eher für einfachere oder lineare Zusammenhänge geeignet.

CTGAN

CTGAN ist ein generatives Deep-Learning-Verfahren für tabellarische Daten. Dabei versucht ein Modell, künstliche Daten zu erzeugen, die möglichst echt aussehen, während ein zweites Modell diese Daten von echten unterscheiden soll.

So verbessert sich die Generierung mit der Zeit. CTGAN kann auch kompliziertere Muster lernen, ist aber aufwendiger und schwieriger zu trainieren.

4 AUFBAU DES PROJEKTS

Verwendete Technologien

Für das Projekt wurden folgende Tools und Bibliotheken verwendet:

- Python 3.13
- SDV 1.35
- scikit-learn
- pandas und numpy
- matplotlib und seaborn

Erstellung des Ausgangsdatensatzes

Da keine echten Patientendaten verwendet wurden, wurde zuerst ein simulierter Datensatz mit **1000 Einträgen** erzeugt. Dieser Datensatz enthält typische medizinische Merkmale, die für Diabetes relevant sein können.

Merkmal	Beschreibung	Wertebereich
alter	Alter der Person	18–89
geschlecht	M/F	kategorisch
bmi	Body-Mass-Index	15–50
blutdruck_sys	systolischer Blutdruck	80–200
cholesterin	Cholesterinwert	100–350
glukose	Nüchtern-Glukose	60–300
hba1c	Langzeit-Blutzucker	3.5–14.0
diabetes	Diagnose	0/1

Die Zielvariable **diabetes** wurde nicht rein zufällig vergeben, sondern über ein einfaches logistisches Modell erzeugt. Dabei hatten insbesondere Alter, BMI, Glukose und HbA1c einen Einfluss auf die Wahrscheinlichkeit einer Diabetes-Diagnose. Dadurch entsteht ein Datensatz, der nicht nur zufällige Werte enthält, sondern auch sinnvolle Muster.

Generierung synthetischer Daten

Aus diesem Ausgangsdatensatz wurden anschliessend zwei synthetische Datensätze mit je **1000 Einträgen** erzeugt:

- einer mit **GaussianCopula**
- einer mit **CTGAN**

So konnte verglichen werden, wie gut die beiden Methoden die Eigenschaften des Ausgangsdatensatzes übernehmen.

Einsatz im ML-Modell

Um zu testen, ob die synthetischen Daten praktisch brauchbar sind, wurde ein **RandomForest-Klassifikator** mit 100 Bäumen verwendet.

Es wurden drei Varianten verglichen:

- Training auf echten Daten
- Training auf GaussianCopula-Daten
- Training auf CTGAN-Daten

Alle Modelle wurden auf demselben **realen Testdatensatz** ausgewertet. So lässt sich vergleichen, wie gut Modelle, die auf synthetischen Daten trainiert wurden, später auf echte Daten funktionieren.

5 ERGEBNISSE

Qualität der synthetischen Daten

Zur Bewertung wurde der **SDV Quality Report** verwendet. Dieser schaut unter anderem darauf, wie ähnlich die Verteilungen einzelner Spalten sind und wie gut Beziehungen zwischen Variablen erhalten bleiben.

Die Resultate waren:

- **GaussianCopula:** 91.65 % Overall Score
- **CTGAN:** 75.44 % Overall Score

GaussianCopula hat in diesem Projekt insgesamt besser funktioniert. Vor allem die Beziehungen zwischen den Merkmalen wurden gut übernommen. CTGAN konnte gewisse Verteilungen zwar noch recht ordentlich abbilden, war aber bei den Zusammenhängen zwischen Variablen schwächer.

Leistung des ML-Modells

Modell	Accuracy	AUC-ROC
Real (Baseline)	0.730	0.781
GaussianCopula	0.650	0.709
CTGAN	0.585	0.689

Wie erwartet war das Modell mit echten Trainingsdaten am besten. Das Modell mit GaussianCopula-Daten war aber noch recht brauchbar und kam relativ nahe an die Baseline heran. CTGAN schnitt schlechter ab.

Ein möglicher Grund dafür ist, dass der Datensatz eher klein und recht strukturiert war. In so einem Fall kann ein einfacheres statistisches Verfahren besser funktionieren als ein aufwendiges GAN-Modell.

Datenschutzbetrachtung

Ein wichtiger Teil des Projekts war die Frage, ob die synthetischen Daten zu nahe an den echten Daten liegen. Dafür wurde eine **Nearest-Neighbor-Distanz** berechnet.

Methode	Mittlere NN-Distanz	Verhältnis zu Real-Real
Real zu Real	0.802	1.00
GaussianCopula zu Real	0.790	0.99
CTGAN zu Real	1.875	2.34

Die Ergebnisse zeigen keine direkten Hinweise darauf, dass echte Datenpunkte kopiert wurden. CTGAN erzeugte sogar deutlich weiter entfernte Punkte. Trotzdem ist das noch keine Garantie für vollständige Anonymität. Es zeigt nur, dass in diesem Versuch keine offensichtliche 1:1-Nähe zu realen Datensätzen festgestellt wurde.

6 CHANCEN UND RISIKEN

Chancen

Synthetische Daten haben mehrere Vorteile:

- Sie können helfen, sensible Daten besser zu schützen.
- Sie erleichtern Forschung und Entwicklung.
- Sie können für Tests und Prototypen verwendet werden.
- Sie machen Data Sharing einfacher.
- Sie sind nützlich, wenn nur wenige reale Daten vorhanden sind.

Risiken

Es gibt aber auch klare Grenzen:

- Synthetische Daten können Verzerrungen aus den Originaldaten übernehmen.
- Wichtige Zusammenhänge können verloren gehen.
- Bei schlechter Generierung kann ein Re-Identifikationsrisiko bestehen.
- “Synthetisch” bedeutet nicht automatisch “anonym”.
- Auch Angriffe wie Membership Inference sind grundsätzlich möglich.

Gerade im Kontext Privatsphäre ist deshalb wichtig, synthetische Daten nicht als perfekte Lösung zu sehen, sondern als einen möglichen Baustein.

7 FAZIT

Das Projekt zeigt, dass synthetische Daten ein sinnvoller Ansatz sein können, um Datenschutz und maschinelles Lernen besser miteinander zu verbinden. Besonders **GaussianCopula** hat in diesem Versuch gute Ergebnisse geliefert. Die Datenqualität war hoch, und auch das darauf trainierte Modell war noch brauchbar.

Trotzdem ersetzen synthetische Daten reale Daten nicht vollständig. Die besten Resultate wurden weiterhin mit echten Trainingsdaten erzielt. Ausserdem bleibt das Thema Datenschutz auch bei synthetischen Daten relevant. Nur weil Daten künstlich erzeugt wurden, heisst das nicht automatisch, dass keinerlei Risiko mehr besteht.

Insgesamt kann man sagen, dass synthetische Daten vor allem für Forschung, Tests und erste Modellentwicklungen interessant sind. Für sensible Anwendungsbereiche sollten sie aber immer zusätzlich geprüft werden, sowohl hinsichtlich ihrer Qualität als auch hinsichtlich möglicher Privacy-Risiken.