Projektarbeit Privatheit, Technologie und Datenschutz

PRIVACY, FS26

Implementierung eines Datenschutzmodells

Carigiet Nico
Sarathchandra Lennan
Schreier Noà
Stocker Raphael
Worthington Eliot

12.04.2026

1 Ausgangslage & Motivation

Unser Fallbeispiel befasst sich mit der Verarbeitung und dem Schutz von Kundendaten eines 3-Sterne-Hotels. Ziel ist es, eine neue, zielgerichtete Marketingkampagne zu starten. Dazu lagert das Hotel die Analyse seiner historischen Gastdaten an eine externe Marketingagentur aus.

Die Agentur hat den Auftrag bekommen, die Daten so zu verarbeiten, dass diese effektiv für das Marketing genutzt werden können. Hauptziel ist es, die Kundschaft in unterschiedliche Marksegmente einzuteilen, um Werbung gezielter schalten zu können.

1.1 Problemstellung

Der zu übermittelnde Datensatz enthält neben direkten Personenbezügen auch quasi-identifizierende sowie sensible Daten der Hotelgäste. Eine direkte, unveränderte Weitergabe dieser Informationen an einen externen Dienstleister stellt ein massives Risiko für die Privatsphäre der Betroffenen dar und verstösst gegen geltende Datenschutzgesetze. Bevor die Daten das interne System des Hotels verlassen, müssen sie daher zwingend datenschutzkonform anonymisiert werden.

1.2 Zielsetzung

Um den gesetzlichen Datenschutz zu gewährleisten und gleichzeitig den Nutzen der Daten für die Agentur zu erhalten, wird in diesem Projekt das ARX Anonymization Tool eingesetzt. Die Aufgabe besteht darin, direkte Identifikatoren zu entfernen und die verbleibenden Quasi-Identifikatoren so zu generalisieren, dass Einzelpersonen nicht mehr aus der Datenmenge herausgefiltert werden können. Das Ziel ist es, den Datensatz so zu transformieren, dass die Marketingagentur wesentliche Trends und Zielgruppen für die Kampagne erkennen kann, ohne jemals Rückschlüsse auf einen konkreten Hotelgast ziehen zu können.

2 Daten

Für das Fallbeispiel wurde von ChatGPT eine Liste von 500 fiktiven Gästen generiert. Bei jedem Hotelgast wurden folgende Attribute festgehalten: Vorname, Nachname, Strasse, Postleitzahl, Herkunftsland, Alter, Geschlecht, Anreisedatum, Anzahl Übernachtungen, Gesamtpreis und Zimmertyp.

Nachfolgend ein Ausschnitt aus dem CSV:

hotel_guests_500_global

First_Name	Last_Name	Street	ZIP_Code	Country	Age	Gender	Arrival_Date	Nights	Total_Price	Room_Type
Hamdan	Al Marri	Jumeirah Street 108	33333	UAE	24	Male	2024-08-25	6	615	Superior
Andrea	Ricci	Via Verdi 79	80100	Italy	44	Male	2024-01-28	1	200	Deluxe
Gabriel	Martin	Rue des Écoles 107	31000	France	50	Male	2024-01-19	3	344	Superior
George	Williams	Main Street 163	SW1A1AA	UK	22	Male	2024-01-30	10	1721	Deluxe
Francesco	Ricci	Via Roma 88	40121	Italy	32	Male	2024-07-05	10	1587	Superior
Ira	Sharma	Brigade Road 123	400001	India	34	Female	2024-06-11	1	139	Superior

3 Datenschutzmodell k-Anonymität

Alle Attribute werden in drei Kategorien Identifying, Quasi-Identifying und Insensitive unterteilt. Die Kategorie Identifying beinhaltet Attribute, mit welchen man direkt die Zielperson erkennt. In der Kategorie Quasi-Identifying sind Attribute enthalten, die in Kombination miteinander Rückschlüsse auf eine bestimmte Person zulassen. In der Kategorie Insensitive sind die Attribute, die für Marketingzwecke wichtig sind und ohne direkte Identifikatoren keine unmittelbare Identifikation einer Person erlauben.

3.1 **Attribute**

First_Name	Identifying
Last_Name	Identifying
Street	Identifying
ZIP_Code	Quasi-Identifying
Country	Quasi-Identifying
Age	Quasi-Identifying
Gender	Quasi-Identifying
Arrival_Date	Quasi-Identifying
Nights	Insensitive
Total_Price	Insensitive
Room_Type	Insensitive

Identifikatoren werden komplett aus dem Datensatz entfernt und die insensitiven Daten werden nicht anonymisiert. Die Quasi-Identifikatoren werden wiederum mithilfe des k-Anonymitäts Datenschutzmodells geschützt. Die Level der Anonymisierung hängen davon

ab, wie viele verschiedene Personen sich in derselben Gruppe befinden und werden so lange erhöht, bis die gewünschte k-Anonymität erreicht wurde. Im schlimmsten Fall werden sie komplett anonymisiert. Wir haben uns für ein K von 3 entschieden, da es in unserem Fall der beste Trade-Off zwischen Anonymisierung und brauchbare Daten lieferte. Dies kann und sollte man besonders bei grösseren Datenmengen noch erhöhen. Auf l-Diversität und t-Closeness wurde verzichtet, da der Datensatz mit 500 Einträgen relativ klein ist und diese Modelle in unserem Fall zu einem deutlich höheren Informationsverlust geführt hätten.

3.2 Hierarchie

Als Generalisierung wird am Beispiel des Alters ein Intervall angegeben. Je nach Anforderung wird das Alter auf ein Intervall von fünf, zehn oder zwanzig Jahren eingegrenzt bzw. im schlimmsten Fall komplett anonymisiert. Dies geschieht auch mit den restlichen Attributen von einer leichten Generalisierung bis hin zur kompletten Anonymisierung. Nachfolgend sind die Hierarchien exemplarisch dargestellt. Die vollständigen Hierarchien wurden im ARX-Tool für alle im Datensatz vorkommenden Werte hinterlegt.

Age

Level-0	Level-1	Level-2	Level-3	Level-4
20	[20,25]	[20,30]	[20,40]	*
29	[25,30]	[20,30]	[20,40]	*

Country

Level-0	Level-1	Level-2	Level-3
Germany	DACH	Europe	*
France	Western Europe	Europe	*
Saudi Arabia	Middle East	Asia	*
United States	North America	North America	*

ZIP Code Masking

Level-0	Level-1	Level-2	Level-3	Level-4	Level-5	Level-6	Level-7	Level-8
xxxxxxxx	xxxxxxx*	xxxxxx**	xxxxx***	xxxx****	xxx*****	xx******	x*******	********

Gender Masking

Level-0	Level-1
F	*
M	*

Anreisedatum

Level-0	Level-1	Level-2
Jahr-Monat-Tag	Monat/Jahr	Quartal

3.3 Suppression Limit

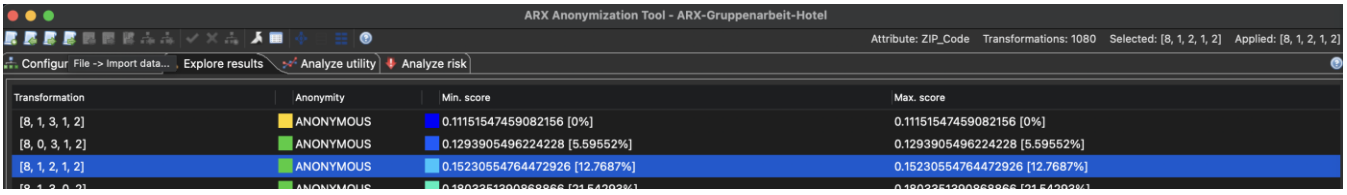
Das Suppression Limit wurde auf 100% gesetzt. Das bedeutet, dass ARX im schlimmsten Fall bis zu 100% der Datensätze unterdrücken dürfte, um die gewählte Datenschutzregel (k-Anonymität) einzuhalten. Unterdrückung heisst, dass einzelne problematische Werte oder ganze Datensätze ausgeblendet werden, wenn sie trotz Generalisierung noch zu eindeutig sind. 100% wurde gewählt, damit ARX bei der Suche nach möglichen Lösungen den grösstmöglichen Spielraum hat. Das heisst aber nicht, dass am Ende wirklich alle Daten entfernt werden. Entscheidend ist später, wie viel Unterdrückung für das Endergebnis tatsächlich nötig war.

4 Auswertung Anonymisierung

Um die Qualität der Anonymisierung zu bewerten, muss der Kompromiss zwischen dem erreichten Schutz der Privatsphäre (Privacy) und dem verbleibenden Nutzen der Daten für die Marketingagentur (Utility) betrachtet werden.

4.1 Auswahl der Lösung

ARX hat mehrere anonyme Transformationslösungen berechnet. Für unsere Auswertung wurde die Lösung [8,1,2,1,2] gewählt, da sie für unseren Use Case den besten Kompromiss zwischen Datenschutz und Nutzbarkeit bietet. Kritische Quasi-Identifikatoren wie ZIP_Code und Gender werden stark anonymisiert, während Age, Country und Arrival_Date noch in einer für Marketingzwecke brauchbaren Form erhalten bleiben.



4.2 Wirkung der Generalisierung

In der gewählten Lösung werden direkte Identifikatoren wie First_Name, Last_Name und Street entfernt. Die Quasi-Identifikatoren werden wie folgt generalisiert:

- ZIP_Code vollständig maskiert (Level 8)
- Gender vollständig maskiert (Level 1)
- Age als 10er-Intervall (Level 2)
- Country als Regionen (Level 1)
- Arrival_Date auf Quartal (Level 2)

Die relevanten Attribute Nights, Total_Price und Room_Type bleiben unverändert erhalten. Dadurch wird die geforderte 3-Anonymität erreicht. Gleichzeitig bleiben für die Marktsegmentierung weiterhin Aussagen zu Herkunft, Altersgruppen und Saisonverhalten möglich.

Output data | Classification performance | Quality models

	rst_Name	ast_Name	Street	ZIP_Code	Country	Age	Gender	rrival_Date	Nights	Total_Price	Room_Type
29	*	*	*	********	Middle East	[30, 40[	*	Q1	6	1144	Deluxe
30	*	*	*	********	Middle East	[30, 40[	*	Q1	5	739	Superior
31	*	*	*	********	Middle East	[30, 40[	*	Q1	4	437	Superior
32	*	*	*	********	Middle East	[30, 40[	*	Q1	2	190	Superior
33	*	*	*	********	Middle East	[40, 50[	*	Q1	12	2552	Deluxe
34	*	*	*	********	Middle East	[40, 50[	*	Q1	9	2010	Deluxe
35	*	*	*	********	Middle East	[40, 50[	*	Q1	2	252	Superior
36	*	*	*	********	Middle East	[40, 50[	*	Q1	1	144	Superior

4.3 Risikoanalyse

Zur Bewertung wurde in ARX das Prosecutor Risk betrachtet, da dieses Modell gut zu unserem Szenario passt. Es geht davon aus, dass ein Angreifer eine konkrete Zielperson kennt und weiss, dass diese Person im Datensatz enthalten ist. Die anderen Angreifermodelle lieferten in unserem Fall sehr ähnliche Werte. Für die gewählte Lösung ergeben sich folgende Werte:

- Lowest prosecutor risk: 8.33%
- Average prosecutor risk: 20.10%
- Highest prosecutor risk: 33.33%

Der höchste Wert von 33.33% ist bei k = 3 plausibel, da dies einer Dreiergruppe entspricht. Das bedeutet, dass eine Person im schlechtesten Fall noch auf drei Datensätze eingegrenzt werden kann.

Vor Anonymisierung Nach Anonymisierung



Im Screenshot ist ersichtlich, dass das Re-Identifikationsrisiko vor der Anonymisierung bei 100% lag. Nach der Anonymisierung sank das höchste Prosecutor Risk auf 33.33%. Dadurch ist eine Person im schlechtesten Fall nicht mehr eindeutig identifizierbar, sondern nur noch einer Dreiergruppe zuordenbar.

5 Fazit

Die Analyse zeigt, dass das Risiko der Re-Identifikation durch die angewendete Anonymisierung deutlich reduziert werden konnte.

Gleichzeitig bleibt der Nutzen der Daten für Marketingzwecke erhalten. Dennoch besteht ein grundlegender Trade-off: Eine stärkere Anonymisierung würde das Risiko weiter reduzieren, jedoch zu einem höheren Informationsverlust führen. Alternativ könnte ein grösserer Datensatz die Bildung grösserer Gruppen ermöglichen und somit den Datenschutz verbessern.

Dies verdeutlicht die zentrale Herausforderung, einen geeigneten Kompromiss zwischen Datenschutz und Datennutzbarkeit zu finden.